

정보통계학과 김성수교수

목 차

- 1. 변수 값 바꾸기 및 결측치 처리
- 2. 변수이름 바꾸기
- 3. 변수 값 라벨
- 4. 변수 값 변환
- 5. 케이스 선택
- 6~7. dplyr 패키지 활용 (1)(2)



1 변수 값 바꾸기 및 결측치 처리



변수 값 바꾸기 및 결측치 처리

예1) x2가 0.11 보다 작은 경우를 99로 바꾸고, 이를 결측치로 처리하는 경우

```
> nwd = wd
> nwd[nwd$x2 < 0.11, "x2"] = 99
> nwd[nwd == 99] = NA
```

예2) 0.9 보다 큰 경우를 모두 결측치로 처리하는 경우,

```
> nwd[nwd > 0.9] = 99
> nwd[nwd == 99] = NA
```

```
R Console
1 0.573 0.1059 0.465 0.538 0.841 0.534
13 0.653 0.1395 0.625 0.519 0.892 0.492
15 0.534 0.1143 0.521 0.570 0.889 0.502
         0.1320 0.505 0.612 0.919
19 0.417 0.1687 0.405 0.415 0.981 0.401
20 0.528 0.1057 0.424 0.566 0.909 0.568
> nwd=wd
```

변수 값 바꾸기 및 결측치 처리

예3) 각 행별, 열별 결측치의 수를 구하는 경우

```
> head(nwd, n=5)
    x1 x2 x3 x4 x5 y
1 0.573 NA 0.465 0.538 0.841 0.534
2 0.651 0.1356 0.527 0.545 0.887 0.535
3 0.606 0.1273 0.494 0.521 NA 0.570
4 0.437 0.1591 0.446 0.423 NA 0.450
5 0.547 0.1135 0.531 0.519 NA 0.548
> rowSums(is.na(nwd))
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
101111010 1 0 0 0 0 0 1 1 2 1 2
> colSums(is.na(nwd))
x1 x2 x3 x4 x5 v
0 3 0 0 11 0
> mywd = na.omit(nwd)
> head(mywd)
    x1 x2 x3 x4 x5
2 0.651 0.1356 0.527 0.545 0.887 0.535
7 0.489 0.1231 0.562 0.455 0.824 0.481
9 0.536 0.1182 0.592 0.464 0.854 0.475
11 0.664 0.1588 0.506 0.481 0.867 0.554
12 0.703 0.1335 0.519 0.484 0.812 0.519
13 0.653 0.1395 0.625 0.519 0.892 0.492
```

- rowSums(is.na(wd)) :각 행별로 결측치의 수를 나타냄.
- colSums(is.na(wd)) :각 열별로 결측치의 수를 나타냄.
- na.omit(wd) : 결측치를 제거

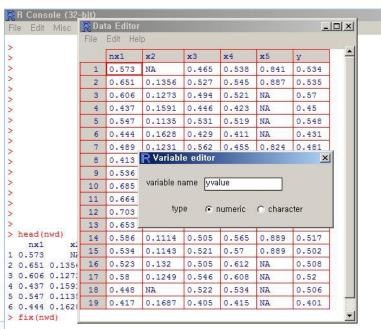
2 변수이름 바꾸기



변수이름 바꾸기

- 변수이름을 바꾸고자 할 때 fix(), names(), colnames() 를 이용
- 이외에도 R 패키지 reshape가 이용

예) fix()를 이용한 대화형 변수이름 바꾸기



예) 변수 이름 바꾸기

- > names(nwd)[6] = "ny"
- > colnames(nwd) = c("a1", "a2", "a3", "a4", "a5", "newy")

변수이름 바꾸기

• R 패키지 reshape를 이용하여 변수이름을 바꿀 때 rename() 함수를 이용

```
> library(reshape)
> names = c("김", "이", "박")
> ages = c(50,44,35)
> mydata <- data.frame(names,ages)
> names(mydata)
[1] "names" "ages"
> mydata
 names ages
> mydata <- rename(mydata, c(names="name"))</pre>
> mydata <- rename(mydata, c(ages="age"))
> mydata
 name age
  김
      50
  0 44
```

3 변수 값 라벨



값 라벨 (Value labels)

■ 숫자로 입력된 값을 라벨로 바꾸기

```
예) 변수 job 1 = 근로자, 2 = 사무직, 3 = 전문가
edu 1 = 무학, 2 = 국졸, 3 = 중졸, 4 = 고졸, 5 = 대졸 로 바꾸기
```

```
> insurance = read.table("c:/Rfolder/data/insurance.txt", header=T)
```

> insurance\$job = factor(insurance\$job, levels=c(1:3), labels=c("근로자","사무직","전문가"))

> insurance\$edu2 = ordered(insurance\$edu, levels=c(1:5), labels=c("무학","국졸","중졸","고졸","대졸"))

> head(insurance)

```
    id
    sex
    job religion
    edu amount
    salary
    edu2

    1 1 m 근로자
    1 3 7.0
    110 중졸

    2 2 m 사무직
    1 4 12.0
    135 고졸

    3 3 f 사무직
    3 5 8.5
    127 대졸

    4 4 f 전문가
    3 5 5.0
    150 대졸

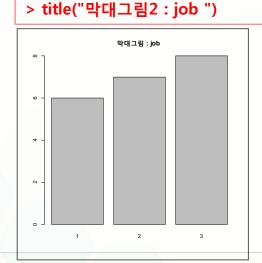
    5 5 m 근로자
    3 3 4.5
    113 중졸

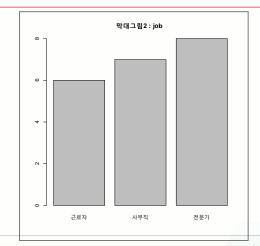
    6 6 m 사무직
    1 2 3.5
    95 국졸
```

- 명목형(nominal data): factor() 함수
- 순서형(ordered data) :ordered() 함수

값 라벨 (Value labels)

예) 막대그림 그리기





4 변수 값 변환(Recode)



변수 값 변환(recode)

예) 어느 제약제품의 약 구매 여부를 조사하였다. 나이별 구매내역은 다음과 같다. 반응변수 purchase 0 = 구매 안함, 1 = 구매함이다. 케이스 수는 100개이다. 이 자료에서 변수 나이(age)의 값을 "40 이하 = 1, 41~60 = 2, 60보다 큰 값 = 3"으로 변환하여보자.

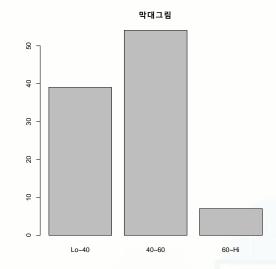
	Α	В	С	
1	id	age	purchase	
2	1	20	0	
3	2	23	0	
4	3	24	0	
5	4	25	1	
6	5	26	0	
7	6	27	0	
8	7	27	0	
9	8	28	0	
10	9	29	0	
11	10	29	0	
12	11	30	0	
13	12	30	0	
14	13	30	0	
15	14	30	1	
16	15	32	0	

```
> install.packages("xlsx")
> library(xlsx)
> drug = read.xlsx("c:/Rfolder/data/drug.xlsx", 1)
# Replace data in the field: Method 1
> drug$agr = drug$age
> drug$agr[drug$agr >= 20 & drug$agr <= 40 ] = 1
> drug$agr[drug$agr > 40 & drug$agr <= 60 ] = 2
> drug$agr[drug$agr > 60 ] = 3
> drug[c(1,20,40, 95),]
   id age purchase agr
1 1 20
20 20 34
40 40 41
95 95 61
```

변수 값 변환(recode)

예) car 패키지의 recode() 를 이용하는 예

```
> # Use recode function in car package : Method 2
> install.packages("car")
> library(car)
> drug$agr2 = drug$age
> drug$agr2 = recode(drug$age, "lo:40=1; 40:60=2; 60:hi=3")
> drug[c(1,20,40, 80),]
   id age purchase agr agr2
       20
20 20 34 0 1
40 40 41 0 2
80 80 56
> drug$agr2 = ordered(drug$agr2, levels=c(1:3),
               labels=c("Lo~40","40~60","60~Hi"))
> agr2.freq=table(drug$agr2)
> agr2.freq
Lo~40 40~60 60~Hi
  39 54 7
> barplot(agr2.freq, main="막대그림")
```



5 케이스 선택



케이스 선택

예) insurance 자료에서 다음과 같은 조건을 만족하는 케이스를 추출해보자.

- ① 성별 = m 인 경우,
- ② 성별 = f 이고, 직업 = 2인 경우,
- > insurance = read.table("c:/Rfolder/data/insurance.txt", header=T)
- > select1 = insurance[insurance\$sex=='m',]
- > head(select1, n=3)

id sex job religion edu amount salary

```
    1
    1
    m
    1
    1
    3
    7.0
    110

    2
    2
    m
    2
    1
    4
    12.0
    135

    5
    5
    m
    1
    3
    3
    4.5
    113
```

- > select2 = insurance[which(insurance\$sex=='f' & insurance\$job==2),]
- > head(select2, n=3)

id sex job religion edu amount salary

```
3 3 f 2 3 5 8.5 127
9 9 f 2 3 4 4.5 110
18 18 f 2 1 5 5.0 110
```

케이스 선택

예) insurance 자료에서 다음과 같은 조건을 만족하는 케이스를 추출해보자.
③ 직업 = 3 이고, 월수입 = 140 이상인 경우

6 dplyr 패키지 활용(1)



dplyr 패키지 소개

- dplyr 패키지 : 데이터 처리를 위한 R 패키지
- 개발자: Hadley Wickham
- 데이터 사전 처리 작업
 - Filtering (데이터 추출)
 - Selecting columns (변수 선택)
 - Adding new variables (변수 추가)
 - Sorting (정렬)
 - Aggregating (집계)
- * 참고: foreign" 패키지 (http://cran.r-project.org/web/packages/plyr/dplyr.pdf)

(1) 데이터 추출 (Filtering)

- 실무에 사용되는 데이터는 변수의 수나 케이스가 크기 때문에 분석 전에 이들 내용을 살펴보는 것이 좋음.
- dim() 함수: (케이스의 수, 변수의 수) 표시,
- tbl_df() 함수: 데이터 프레임. 효율적인 출력결과를 보여줌.

```
> library(dplyr)
> dim(insurance)
[1] 22 7
> tbl df(insurance)
Source: local data frame [22 x 7]
   id sex job religion edu amount salary
                    1 3 7.0
                                    110
                          12.0
                                    135
                       4 10.0
21 21
                                     95
                            12.0
                                     88
22 22
```

(1) 데이터 추출 (Filtering)

```
예1) tbl_df()
```

Diverted (int)

```
> library(nycflights13)
> dim(flights)
[1] 227496
> tbl_df(flights)
Source: local data frame [227, 496 x 21]
   Year Month DayofMonth DayOfWeek DepTime ArrTime UniqueCarrier FlightNum
   2011
                                      1400
                                              1500
                                                                       428
                                                              AA
                                              1501
                                                                       428
   2011
                                      1401
                                      1352
                                              1502
                                                                       428
   2011
   2011
                                      1403
                                              1513
                                                                       428
   2011
                                              1507
                                                                       428
                                      1405
   2011
                                      1359
                                              1503
                                                                       428
                                              1509
                                                                       428
   2011
                                      1359
   2011
                                      1355
                                              1454
                                                                       428
   2011
                                      1443
                                              1554
                                                                       428
10 2011
                                      1443
                                              1553
                                                                       428
Variables not shown: TailNum (chr), ActualElapsedTime (int), AirTime (int),
 ArrDelay (int), DepDelay (int), Origin (chr), Dest (chr), Distance (int),
  TaxiIn (int), TaxiOut (int), Cancelled (int), CancellationCode (chr),
```

(1) 데이터 추출 (Filtering)

예2) sex = 'm'이고, edu = 3인 케이스를 추출하는 예 (AND 조건문은 콤마(,)나 & 연산자를 사용)

예3) sex = 'm' 또는 edu = 3인 케이스를 추출하는 예 (OR 조건문은 | 연산자를 사용)

(2) 변수 선택

변수선택은 select() 사용

```
> head(insurance)
   sex job religion edu amount salary
                      3
                          7.0
                                 110
                        12.0
                              135
                  3 5 8.5 127
                 3 5 5.0 150
3 3 4.5 113
                          3.5
                                95
> sel_3 = select(insurance, sex, job, amount, salary)
> head(sel_3, 3)
 sex job amount salary
          7. 0
                 110
   m 2 12.0 135
   f 2 8.5
                  127
```

(2) 변수 선택

filter() 함수와 같이 사용 가능함.
 인접한 열을 추출할 때는 연산자 : 를 사용.

```
> sel_4 = filter(select(insurance, sex, job, amount, salary), job==1)
> head(sel 4, 3)
 sex job amount salary
   m 1 7.0 110
  m 1 4.5 113
   m 1 17.0 200
> sel_5 = select(insurance, job:salary)
> head(sel 5, 3)
 job religion edu amount salary
               3 7.0
                        110
           1 4 12.0 135
           3 5 8.5
                        127
```

(3) 변수 추가

• 새로운 변수를 만들어 추가하는 경우에 mutate() 함수가 이용됨.

※ 참고: cbind() 를 사용하는 경우

- > amopersal = insurance\$amount / insurance\$salary
- > insu_add2 = cbind(insurance, amopersal)

(4) 정렬

• 크기순으로 정렬하기 위해서는 arrange() 함수가 이용됨.

예1) sex와 job을 기준으로 오름차순으로 정렬하는 예

예2) sex와 job을 기준으로 내림차순으로 정렬하는 예

(5) 요약결과

• 데이터를 정렬한 뒤, 그룹별 요약 결과 보기 : group_by() 함수, summarise() 함수

예) 변수 job 에 따라 amount 와 salary 의 평균을 보기

```
> ins_job = arrange(insurance, job)
> ins_job_g = group_by(ins_job, job)
> ins_job_gm = summarize(ins_job_g, amMean=mean(amount), aSal=mean(salary))
> ins_job_gm
Source: local data frame [4 x 3]

job amMean aSal
1 1 10. 583333 NA
2 2 6. 571429 109. 5714
3 3 7. 000000 118. 3750
4 NA 6. 000000 110. 0000
```

(6) chain 기능

- 여러 명령을 연결해서 한번에 수행할 수 있도록 하는 기능
- 연결 기능은 %〉% ("then" 즉, "그리고"로 명명)로 이루어짐.

예) insurance 자료에서 amount, salary 두 변수를 선택하여, salary > 130 이상인 케이스를 추출하는 예

```
> b1 = select(insurance, amount, salary)
> b2 = filter(b1, salary > 130)
> b2
   amount salary
1    12    135
2    5    150
3    17    200
4    7    150
5    6    138
```

7 dplyr 패키지 활용(2)

Ref: https://rpubs.com/justmarkham/dplyr-tutorial



Loading dplyr and an example dataset (1)

- > library(dplyr)
- > library(hflights)
- > # hflights is flights from two Houston airports in 2011
- > data(hflights)
- > head(hflights)

```
Year Month DayofMonth DayOfWeek DepTime ArrTime UniqueCarrier FlightNum
5424 2011
                                         1400
                                                 1500
                                                                           428
5425 2011
                                         1401
                                                 1501
                                                                           428
5426 2011
                                         1352
                                                 1502
                                                                           428
5427 2011
                                         1403
                                                 1513
                                                                           428
                                         1405
                                                 1507
                                                                           428
5428 2011
5429 2011
                                         1359
                                                 1503
                                                                           428
     TailNum ActualElapsedTime AirTime ArrDelay DepDelay Origin Dest Distance
5424 N576AA
                                             -10
                                                              IAH DFW
                                                                            224
5425
     N557AA
                                                                            224
                                                                            224
5426
     N541AA
5427
      N403AA
                                                              IAH DFW
                                                                            224
                                                              IAH DFW
                                                                            224
5428
      N492AA
5429 N262AA
                                                              TAH DFW
                                                                            224
     TaxiIn TaxiOut Cancelled CancellationCode Diverted
5424
5425
5426
5427
5428
5429
```

Loading dplyr and an example dataset (2)

```
> flights = tbl df(hflights)
> flights
Source: local data frame [227, 496 x 21]
   Year Month DayofMonth DayOfWeek DepTime ArrTime UniqueCarrier FlightNum TailNum
   2011
                                               1500
                                                                              N576AA
                                       1400
   2011
                                       1401
                                               1501
                                                                              N557AA
   2011
                                       1352
                                               1502
                                                                              N541AA
   2011
                                       1403
                                               1513
                                                                         428
                                                                              N403AA
   2011
                                       1405
                                               1507
                                                                              N492AA
   2011
                                       1359
                                               1503
                                                                              N262AA
   2011
                                       1359
                                               1509
                                                                              N493AA
                                       1355
                                               1454
                                                                              N477AA
                                                                         428
   2011
                                       1443
                                               1554
                                                                              N476AA
                                       1443
                                               1553
                                                                              N504AA
Variables not shown: ActualElapsedTime (int), AirTime (int), ArrDelay (int).
DepDelay
  (int), Origin (chr), Dest (chr), Distance (int), TaxiIn (int), TaxiOut (int),
  Cancelled (int), CancellationCode (chr), Diverted (int)
```

- * tbl_df creates a "local data frame"
- * Local data frame is simply a wrapper for a data frame that prints nicely

Filter: Keep rows matching criteria(1)

- > # base R approach to view all flights on January 1
- > flights[flights\$Month==1 & flights\$DayofMonth==1,]
- > # dplyr approach
- > # note: you can use comma or &(ampersand) to represent AND condition
- > filter(flights, Month==1, DayofMonth==1)

Source: local data frame [552 x 21]

	Year	Month	DayofMonth	DayOfWeek	DepTime	ArrTime	UniqueCarrier	FlightNum	TailNum
1	2011	1	1	6	1400	1500	AA	428	N576AA
2	2011	1	1	6	728	840	AA	460	N520AA
3	2011	1	1	6	1631	1736	AA	1121	N4WVAA
4	2011	1	1	6	1756	2112	AA	1294	N3DGAA
5	2011	1	1	6	1012	1347	AA	1700	N3DAAA
6	2011	1	1	6	1211	1325	AA	1820	N593AA
7	2011	1	1	6	557	906	AA	1994	N3BBAA
8	2011	1	1	6	1824	2106	AS	731	N614AS
9	2011	1	1	6	654	1124	B6	620	N324JB
10	2011	1	1	6	1639	2110	В6	622	N324JB

Variables not shown: ActualElapsedTime (int), AirTime (int), ArrDelay (int), DepDelay (int), Origin (chr), Dest (chr), Distance (int), TaxiIn (int), TaxiOut (int), Cancelled (int), CancellationCode (chr), Diverted (int)

Filter: Keep rows matching criteria(2)

```
> # use pipe for OR condition
> filter(flights, UniqueCarrier=="AA" | UniqueCarrier=="UA")
Source: local data frame [5, 316 x 21]
   Year Month DayofMonth DayOfWeek DepTime ArrTime UniqueCarrier FlightNum TailNum
   2011
                                              1500
                                                                            N576AA
                                      1400
   2011
                                       1401
                                              1501
                                                                             N557AA
   2011
                                      1352
                                              1502
                                                                        428
                                                                            N541AA
   2011
                                      1403
                                              1513
                                                                        428
                                                                            N403AA
   2011
                                      1405
                                              1507
                                                                            N492AA
                                                                        428
   2011
                                      1359
                                              1503
                                                                            N262AA
   2011
                                      1359
                                              1509
                                                                            N493AA
                                      1355
   2011
                                              1454
                                                                        428
                                                                            N477AA
   2011
                                      1443
                                              1554
                                                                            N476AA
10 2011
                                       1443
                                               1553
                                                                             N504AA
Variables not shown: ActualElapsedTime (int), AirTime (int), ArrDelay (int),
DepDelay
  (int), Origin (chr), Dest (chr), Distance (int), TaxiIn (int), TaxiOut (int),
  Cancelled (int), CancellationCode (chr), Diverted (int)
```

select: Pick columns by name(1)

- > # base R approach to select DepTime, ArrTime, and FlightNum columns
- > flights[, c("DepTime", "ArrTime", "FlightNum")]

```
> # dplyr approach
> select(flights, DepTime, ArrTime, FlightNum)
Source: local data frame [227, 496 x 3]
   DepTime ArrTime FlightNum
      1400
              1500
                         428
      1401
              1501
                         428
      1352
              1502
                         428
      1403
              1513
                         428
      1405
              1507
                         428
              1503
                         428
      1359
              1509
                         428
      1359
                         428
      1355
              1454
      1443
              1554
                         428
      1443
              1553
                         428
```

select: Pick columns by name(2)

- > # use colon to select multiple contiguous columns, and use `contains` to match columns by name
- > # note: `starts_with`, `ends_with`, and `matches` (for regular expressions) can also be used to match
- > # columns by name
- > select(flights, Year:DayofMonth, contains("Taxi"), contains("Delay"))

Source: local data frame [227, 496 x 7]

	Year	Month	DayofMonth	Tax i In	TaxiOut	ArrDelay	DepDelay
1	2011	1	1	7	13	-10	0
2	2011	1	2	6	9	-9	1
3	2011	1	3	5	17	-8	-8
4	2011	1	4	9	22	3	3
5	2011	1	5	9	9	-3	5
6	2011	1	6	6	13	-7	-1
7	2011	1	7	12	15	-1	-1
8	2011	1	8	7	12	-16	-5
9	2011	1	9	8	22	44	43
10	2011	1	10	6	19	43	43

Chaining

- Usual way to perform multiple operations in one line is by nesting
- Can write commands in a natural order by using the %>% infix operator (which can be pronounced as "then")

```
> a1 = select(flights, UniqueCarrier, DepDelay)
> a2 = filter(a1, DepDelay > 60)
> na2 = flights %>%
              select(UniqueCarrier, DepDelay) %>%
                    filter(DepDelay > 60)
> na2
Source: local data frame [10.242 x 2]
  UniqueCarrier DepDelay
                     90
                    125
                     70
                     61
```

arrange: Reorder rows

- > # base R approach to select UniqueCarrier and DepDelay columns and sort by DepDelay
- > flights[order(flights\$DepDelay), c("UniqueCarrier", "DepDelay")]

```
> flights %>%
    select(UniqueCarrier, DepDelay) %>%
    arrange(DepDelay)
Source: local data frame [227, 496 x 2]
  UniqueCarrier DepDelay
                     -33
                    -19
                    -18
                    -17
                    -17
                    -17
```

```
# use `desc` for descending
flights %>%
select(UniqueCarrier, DepDelay) %>%
arrange(desc(DepDelay))
```

mutate: Add new variables

- > # base R approach to create a new variable Speed (in mph)
- > flights\$Speed <- flights\$Distance / flights\$AirTime*60
- > flights[, c("Distance", "AirTime", "Speed")]

```
> flights %>%
    select(Distance, AirTime) %>%
    mutate(Speed = Distance/AirTime*60)
Source: local data frame [227, 496 x 3]
  Distance AirTime
                       Speed
        224
                 40 336,0000
        224
                45 298, 6667
       224
                48 280,0000
                39 344, 6154
        224
       224
                44 305, 4545
       224
                45 298, 6667
                43 312, 5581
       224
       224
                40 336,0000
                41 327, 8049
        224
        224
                 45 298, 6667
```

summarise: Reduce variables to values(1)

- group_by: creates the groups that will be operated on
- summarise : uses the provided aggregation function to summarise each group

```
> flights %>%
    group_by(Dest) %>%
    summarise(avg_delay = mean(ArrDelay, na.rm=TRUE))
Source: local data frame [116 x 2]
  Dest avg_delay
         7. 226259
         5.839437
         4.000000
         6.840095
        26.080645
         6. 794643
         8. 233251
         7. 448718
         9.973988
   BFL -13, 198807
```

summarise: Reduce variables to values(2)

 summarise_each : allows you to apply the same summary function to multiple columns at once

```
> flights %>%
    group_by(UniqueCarrier) %>%
    summarise each(funs(mean), Cancelled, Diverted)
Source: local data frame [15 x 3]
   UniqueCarrier
                  Cancelled
                               Diverted
             AA 0. 018495684 0. 001849568
             AS 0.000000000 0.002739726
             B6 0.025899281 0.005755396
             CO 0.006782614 0.002627370
             DL 0.015903067 0.003029156
             EV 0. 034482759 0. 003176044
             F9 0.007159905 0.000000000
             FL 0.009817672 0.003272557
             MQ 0.029044750 0.001936317
             00 0.013946828 0.003486707
             UA 0. 016409266 0. 002413127
             US 0. 011268986 0. 001469868
             WN 0.015504047 0.002293629
             XE 0. 015495599 0. 003449550
             YV 0.012658228 0.000000000
```