

8강 증화임의추출법(3)

정보통계학과 이기재교수

학/습/목/차

1. 표본배분 – 네이만배분법, 최적배분법
2. 사후총화
3. 총화임의추출법과 단순임의추출법의 비교
4. 엑셀을 활용한 실습

(1) 네이만배분법

- 각 층의 크기와 층별 변동의 정도를 동시에 고려한 표본배정 방법
- 변동이 큰 층에 대해서는 상대적으로 많은 표본을 배정
- 층별 조사비용은 별 차이가 없고, 변동의 정도가 많이 나는 경우에 적당

- 배분공식 :
$$n_h = n \times \frac{N_h S_h}{\sum_{k=1}^H N_k S_k}, \quad h = 1, 2, \dots, H$$

- 네이만배분일 때의 표본크기 결정 공식 :
$$n = \frac{\left(\sum_{h=1}^H N_h S_h \right)^2}{N^2 D + \sum_{h=1}^H N_h S_h^2}$$

(1) 네이만배분법

❖ 예제 4-8

▶ 네이만배분법 적용 예제

층	규모(종업원수)	제조업체의 수(N_h)	표본분산(s_h^2)
1	49인 이하	18,000	80^2
2	50 – 99인	4,000	200^2
3	100 – 249인	2,000	600^2
4	250인 이상	500	$1,900^2$

$$\sum_{k=1}^4 N_k S_k = 18,000 \times 80 + 4,000 \times 200 + 2,000 \times 600 + 500 \times 1,900 = 4,390,000$$

$$\blacksquare \text{ 층1 : } n_1 = 500 \times \frac{18,000 \times 80}{4,390,000} \doteq 164 \quad \blacksquare \text{ 층2 : } n_2 = 500 \times \frac{4,000 \times 200}{4,390,000} \doteq 91$$

$$\blacksquare \text{ 층3 : } n_3 = 500 \times \frac{2,000 \times 600}{4,390,000} \doteq 137 \quad \blacksquare \text{ 층4 : } n_4 = 500 \times \frac{500 \times 1,900}{4,390,000} \doteq 108$$

(2) 최적배분법

- 주어진 비용 하에서 추정량의 분산을 최소화시키거나 주어진 분산의 범위 하에서 비용을 최소화시키는 방법
- 층별로 단위당 조사비용에 차이가 있는 경우에 쓰이는 방법

- 배분공식 :
$$n_h = n \times \frac{N_h S_h / \sqrt{c_h}}{\sum_{k=1}^H N_k S_k / \sqrt{c_k}} , h = 1, 2, \dots, H$$

- 최적배분일 때의 표본크기 결정 공식 :

$$n = \frac{\left(\sum_{h=1}^H N_h S_h / \sqrt{c_h} \right) \left(\sum_{k=1}^H N_k S_k / \sqrt{c_k} \right)}{N^2 D + \sum_{h=1}^H N_h S_h^2}$$

(2) 최적배분법

❖ 예제 4-9

▶ 최적배분법 적용 예제

층	규모(종업원수)	제조업체의 수(N_h)	표본분산(s_h^2)	조사비용(c_h)
1	49인 이하	18,000	80^2	1
2	50 – 99인	4,000	200^2	1
3	100 – 249인	2,000	600^2	2
4	250인 이상	500	$1,900^2$	3

$$\sum_{k=1}^H N_k S_k / \sqrt{c_k} = \frac{18,000 \times 80}{\sqrt{1}} + \frac{4,000 \times 200}{\sqrt{1}} + \frac{2,000 \times 600}{\sqrt{2}} + \frac{500 \times 1,900}{\sqrt{3}} = 3,637,010$$

$$\blacksquare \text{ 층1 : } n_1 = 500 \times \frac{1,440,000}{3,637,010} \doteq 198 \quad \blacksquare \text{ 층2 : } n_2 = 500 \times \frac{800,000}{3,637,010} \doteq 110$$

$$\blacksquare \text{ 층3 : } n_3 = 500 \times \frac{848,528}{3,637,010} \doteq 117 \quad \blacksquare \text{ 층4 : } n_4 = 500 \times \frac{548,482}{3,637,010} \doteq 75$$

학/습/목/차

1. 표본배분 – 네이만배분법, 최적배분법
2. 사후총화
3. 총화임의추출법과 단순임의추출법의 비교
4. 엑셀을 활용한 실습

사후총화의 필요성을 나타내는 예 : 평균 몸무게 추정

남자: 800	여자: 200
남자: 5만	여자: 5만

- 남자 표본평균 = 55kg, 여자 표본평균 = 45kg
- 남자가 표본에 과다하게 반영 → 과다 추정의 가능성

사후층화(post-stratification)의 개념

- 단순임의표본을 이용할 경우는 이미 알고 있는 모집단 특성 비율을 반영 못함
- 단순임의추출을 이용했지만 추정단계에서 모집단의 사전정보를 이용
- 층화임의추출 : 표본설계 단계에서 층화변수를 기준으로 층화
사후층화 : 표본추출이 이루어지고 난 이후 표본의 데이터를 층화

예

▶ 도시 시민들의 평균 몸무게 추정

$$\begin{aligned} \text{평균의 사후 층화 추정량} &= (\text{남자의 평균} \times 0.5) + \\ &\quad (\text{여자의 평균} \times 0.5) \\ &= (55 \times 0.5) + (45 \times 0.5) = 50\text{kg} \end{aligned}$$

〈참고〉 단순 표본평균 = 53kg

모평균에 대한 사후층화 추정량

- 표본데이터

▶ $y_1, y_2, \dots, y_n \rightarrow$ 사후층화 : $(y_{11}, y_{12}, \dots, y_{1n_1}), \dots, (y_{H1}, y_{H2}, \dots, y_{Hn_H})$

- 사후층화추정량

▶ $\bar{y}_{post} = \sum_{h=1}^H W_h \cdot \bar{y}_{ph}$, 여기서 $W_h = \frac{N_h}{N}$, $\bar{y}_{ph} = \frac{1}{n_h} \sum_{i=1}^{n_h} y_{hi}$

- 분산추정량

▶ $\hat{V}(\bar{y}_{post}) = \frac{N-n}{Nn} \cdot \sum_{h=1}^H W_h s_{ph}^2 + \frac{1}{n^2} \sum_{h=1}^H (1 - W_h) s_{ph}^2$

모평균에 대한 사후층화 추정량

❖ 예제 4-10

▶ 사후층화 적용 예제

❖ 모집단 - 도매계정:40%, 소매계정 : 60%

❖ 표 본 - 도매계정:70%, 소매계정 : 30%

도매계정	소매계정
$n_1 = 70$	$n_2 = 30$
$\bar{y}_{p1} = 520$	$\bar{y}_{p2} = 280$
$s_{p1} = 210$	$s_{p2} = 90$

- 평균에 대한 사후층화 추정값 : $\bar{y}_{post} = 0.4 \times 520 + 0.6 \times 280 = 376$
- 분산추정 : $\hat{V}(\bar{y}_{post}) = \frac{1}{n} \cdot \sum_{h=1}^2 W_h s_{ph}^2 + \frac{1}{n^2} \sum_{h=1}^2 (1 - W_h) s_{ph}^2 = 227.97$
- 신뢰구간 : $376 \pm 2 \sqrt{227.97} \leftrightarrow 376 \pm 30$

학/습/목/차

1. 표본배분 – 네이만배분법, 최적배분법
2. 사후총화
3. 총화임의추출법과 단순임의추출법의 비교
4. 엑셀을 활용한 실습

층화추출은 반드시 단순임의추출보다 더 효과적인가?

- 적절한 층화변수 선택 (층화변수와 조사변수의 상관관계가 높을 때)

❖ 예제 4-11

▶ 부적절한 층화의 예 - 체인망으로 층화

층	N_h	n_h	표본데이터							\bar{y}_h	s_h^2
1	30	5	92	88	100	108	96			96.8	59.2
2	42	7	89	97	91	103	109	99	98	98.0	46.3
3	36	6	106	94	98	91	91	94		95.7	32.3
4	36	6	90	108	92	89	111	92		97.0	96.0
합계	144	24									

1. 층화추출일 때의 평균 판매량 추정

- $\bar{y}_{st} = \frac{1}{N} \sum_{h=1}^4 N_h \bar{y}_h = 96.9$
- $\hat{V}(\bar{y}_{st}) = \frac{1}{N^2} \sum_{h=1}^H N_h^2 \frac{N_h - n_h}{N_h} \frac{s_h^2}{n_h} = 2.01$

층화추출은 반드시 단순임의추출보다 더 효과적인가?

- 적절한 층화변수 선택 (층화변수와 조사변수의 상관관계가 높을 때)

❖ 예제 4-11

▶ 부적절한 층화의 예 - 체인망으로 층화

층	N_h	n_h	표본데이터							\bar{y}_h	s_h^2
1	30	5	92	88	100	108	96			96.8	59.2
2	42	7	89	97	91	103	109	99	98	98.0	46.3
3	36	6	106	94	98	91	91	94		95.7	32.3
4	36	6	90	108	92	89	111	92		97.0	96.0
합계	144	24									

2. 단순임의추출법일 때의 추정

- $\bar{y} = \frac{1}{24}(92 + 88 + \dots + 89 + 111 + 92) = 96.9$
- $\hat{V}(\bar{y}) = \frac{N-n}{n} \cdot \frac{s^2}{n} = 1.77$

층화추출은 반드시 단순임의추출보다 더 효과적인가?

- 적절한 층화변수 선택 (층화변수와 조사변수의 상관관계가 높을 때)

❖ 예제 4-11

▶ 부적절한 층화의 예 - 체인망으로 층화

층	N_h	n_h	표본데이터							\bar{y}_h	s_h^2
1	30	5	92	88	100	108	96			96.8	59.2
2	42	7	89	97	91	103	109	99	98	98.0	46.3
3	36	6	106	94	98	91	91	94		95.7	32.3
4	36	6	90	108	92	89	111	92		97.0	96.0
합계	144	24									

3. 두 추정값의 비교

- 단순임의추출에서의 추정분산 = 1.77
 < 층화추출에서의 추정분산 = 2.01
- 체인망을 층화기준으로 삼은 것은 부적절
 <참고> 좋은 층화 : 층내 동질적, 층간 이질적

층화추출은 반드시 단순임의추출보다 더 효과적인가?

- 적절한 층화변수 선택 (층화변수와 조사변수의 상관관계가 높을 때)

✚ 예제 4-12

▶ 적절한 층화의 예 – 각 점포의 전년 판매량 기준 층화

층	N_h	n_h	표본데이터	\bar{y}_h	s_h^2
1(대)	41	7	100 109 108 111 106 103 96	104.7	28.6
2(중)	43	7	94 98 91 97 91 108 98	96.7	33.9
3(소)	60	10	92 88 89 99 90 92 91 89 94 92	91.6	10.0
합계	144	24			

층화추출은 반드시 단순임의추출보다 더 효과적인가?

- 적절한 층화변수 선택 (층화변수와 조사변수의 상관관계가 높을 때)

❖ 예제 4-12

▶ 적절한 층화의 예 - 각 점포의 전년 판매량 기준 층화

1. 층화추출일 때의 평균 판매량 추정

$$\begin{aligned}\bar{y}_{st} &= \frac{1}{N} \sum_{h=1}^3 N_h \bar{y}_h \\ &= \frac{1}{144} (41 \times 104.7 + 43 \times 96.7 + 60 \times 91.6) = 96.9 \\ \hat{V}(\bar{y}_{st}) &= \frac{1}{N^2} \sum_{h=1}^H N_h^2 \frac{N_h - n_h}{N_h} \frac{s_h^2}{n_h} \\ &= \frac{1}{144^2} \left[41(41 - 7) \times \frac{28.6}{7} + 43(43 - 7) \times \frac{33.9}{7} \right. \\ &\quad \left. + 60(60 - 10) \times \frac{10}{10} \right] = 0.78\end{aligned}$$

층화추출은 반드시 단순임의추출보다 더 효과적인가?

- 적절한 층화변수 선택 (층화변수와 조사변수의 상관관계가 높을 때)

✚ 예제 4-12

- ▶ 적절한 층화의 예 - 각 점포의 전년 판매량 기준 층화

2. 단순임의추출법일 때의 추정

- $\bar{y} = 96.9$, $\hat{V}(\bar{y}) = 1.77$

3. 두 추정값의 비교

- 단순임의추출에서의 추정분산 = 1.77 > 층화추출에서의 추정분산 = 0.78
- 적절한 층화로 인해 효율을 2.3배(= 1.77/0.78) 높인 사례

학/습/목/차

1. 표본배분 – 네이만배분법, 최적배분법
2. 사후총화
3. 총화임의추출법과 단순임의추출법의 비교
4. 엑셀을 활용한 실습

↳ <실습하기>에서 자세히 다룸



Korea National Open University
이 강의는
강의용 휴대폰(U-KNOU 서비스 휴대폰)으로도
다시 볼 수 있습니다.

다시 볼 수 있습니다.